

# Bulk Web-Crawler mit Spring Batch



# **Anforderung - funktional**

Wir wollen automatisiert Überprüfung, ob bestimmte Produkte (Bücher) in einem Online-Shop gelistet sind.

| Site      | Produkt | Status    |
|-----------|---------|-----------|
| AMAZON_DE | 0815    | FOUND     |
| HIVE_UK   | 1234    | NOT_FOUND |
|           |         |           |



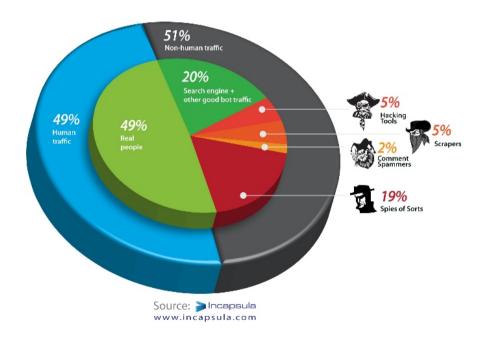
# Anforderung - nicht-funktional

- Nicht-funktional:
  - REST-Prinzipien
  - optimiert ist f\u00fcr Hintergrundverarbeitung
  - Monitoring
  - batchfähig
  - Parallelisierung über Threads



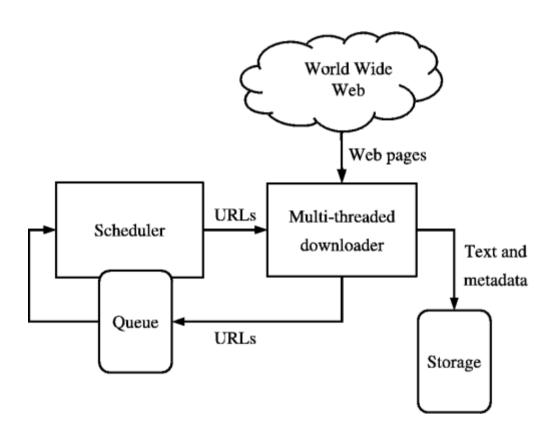
#### Web-Crawler

- aka. internet bots, Spiders, Indexers, Scrapers
- Web-Crawler verursachen ca. 50 % des Internet Traffics weltweit!





# Crawler: prinizieller Aufbau



Quelle: http://en.wikipedia.org/wiki/Web\_crawler



#### **Crawler: Richtlinien**

- selection policy
- re-visit policy
- politeness policy
- parallelization policy



## Analyse der Zielseite

http://www.hive.co.uk/

ISBN 978-1-408-85567-6

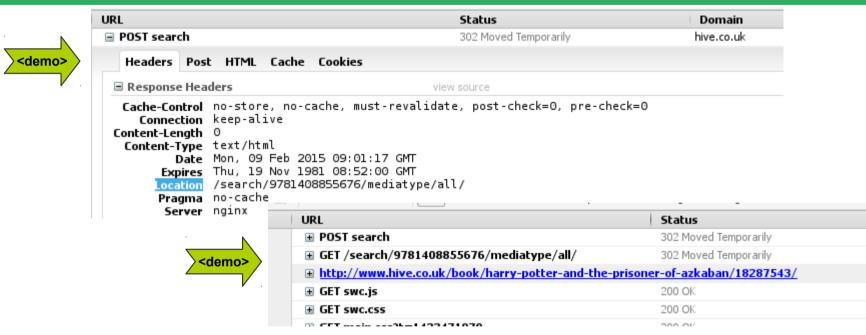
"Harry Potter And The Prisoner Of Azkaban"







#### Request-Sequenz



- POST search zur Such-Seite
- GET /search/9781408855676/mediatype/all/
- GET /book/harry-potter-and-the-prisoner-of-azkaban/18287543/



#### "Canonical Links"

- Identischer Seiten-Content wird unter verschiedenen URLs angeboten (Domain-intern, aber auch domainübergreifend)
- Beispiele:
  - http://.../search/9781408855676/mediatype/all/
  - http://.../book/harry-potter-and-the-prisoner-of-azkaban/18287543/

\_



#### Request-Seqzenz



| Status                | Domain     | Size    |
|-----------------------|------------|---------|
| 302 Moved Temporarily | hive.co.uk | 0 B     |
| 302 Moved Temporarily | hive.co.uk | 0 B     |
| 200 OK                | hive.co.uk | 52.9 KB |

- POST, o bytes Content, nur HTTP redirect
- GET, o bytes Content, nur HTTP redirect
- GET, 52.9 KB Content
- Danach läd der Browser nur noch CSS/JS Resourcen vom Webserver.



## **Analyse URL-Aufbau**

http://www.hive.co.uk/book/harry-potter-and-the-prisoner-of-azkaban/18287543/



Suche nach "18287543" im HTML-Code ...

```
Edit div.mc_sku < div#mc_data < body.js-enabled < html

<!DOCTYPE html PUBLIC "-//W3C//DTD XHTML 1.0 Transitional//EN" "http://www.w3.org/TR/xhtml;

<html xmlns:fb="http://www.facebook.com/2008/fbml" xmlns="http://www.w3.org/1999/xhtml">

+ <head>

- <bdy class="js-enabled" data-twttr-rendered="true">

- <div id="mc_data" style="display: none;">

- <div class="mc_event">

- <div class="mc_event">VIEW </div>

- <div class="mc_retailer">

- <div class="mc_event">

- <div class="mc_sku">18287543</div>

- </div>

- <div class="mc_sku">18287543</div>

- <div class="mc_sku">

- <div class="mc_sku"</di>
- <div class="mc_sk
```

## Algorithmus 0.1

- 1. perform an HTTP GET request to http://www.hive.co.uk/search/9781408855676/mediatype/all/
- 2. if HTTP response returns code 302, then product was found.

Der Algorithmus ist unvollständig, da er den Fall nicht berücksichtigt, wenn ein Produkt nicht gefunden wurde.

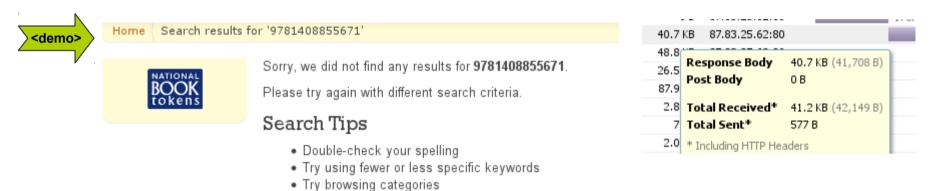
## Algorithmus 0.2

- 1. perform an HTTP GET request to http://www.hive.co.uk/search/9781408855676/mediatype/all/
- 2. if HTTP response returns code 302, then product was found.
- 3. if HTTP response returns code 200 the product was not found.



# **Optimierung**

Im Fehlerfall antwortet der Web-Server mit einer Fehlerseite:



Dieser Request umfasst einen Download von ca. **40 KB** für jedes Produkt, das **nicht** gefunden wurde.

Lösung: GET-Request durch HEAD-Request ersetzten



HEAD http://www.hive.co.uk/search/9781408855676/mediatype/all/

302 Found 🔼 0 bytes

**②** 638 ms

## Algorithmus 1.0

- 1. perform an HTTP HEAD request to http://www.hive.co.uk/search/9781408855676/mediatype/all/
- 2. if HTTP response returns code 302, then product was found.
- 3. if HTTP response returns code 200 the product was not found.

## **Einschub: Content Inspection**

Der Algorithmus basiert nur auf HTTP-Ebene und berücksichtigt <u>keine</u> HTML-Seiteninhalte.

- Durch Content Inspection werden Informationen aus dem HTML extrahiert:
  - element by id
  - element by css style
  - Werte in Tags (z.B. <img src=...>)
  - hidden divs (display:none)
  - Ausgehende Links ( <a href=...>)



## Implementierung - Teil 1

- Setup Java-Main mit Maven und Apache HTTPClient
- Absetzen des HEAD-Request
- Absetzen GET-Request und Download des HTML-Contents
- HTML Content Inspection mit htmlcleaner

#### Frameworks/Libraries

- Spring 4.1
- Spring Batch 3.0
- Apache HTTPClient 4.3
- HtmlCleaner 2.8
- EclipseLink 2.5.2
- PostgreSQL 9.3
- Maven 3
- Java 8

#### htmlcleaner

- API ähnlich SAX (XML)
- Visitor-Pattern
  - resourcenschonend
  - skalierbar
- Statushandling:
  - Boolean-Flag: found = true/false
- Single-Pass vs. Multi-Pass



# HACKING...





# Implementierung – Teil 2

- Setup Spring Batch
- Konfiguration der Jobs
- Batch-Metadaten-Tabellen



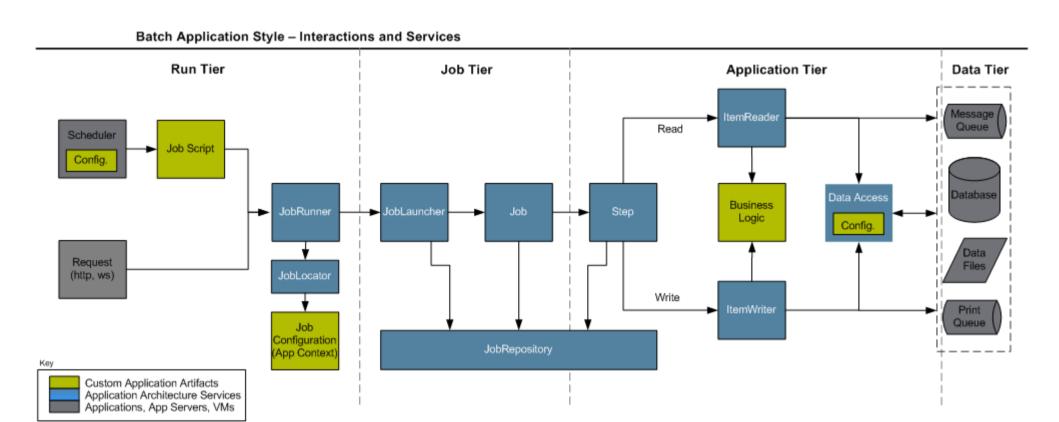
# **Spring Batch**

"process large volumns of information without user interaction"

- Konzepte
  - Jobs
  - Steps
  - Tasklets
  - Chunk oriented: Reader-Processor-Writer
- AOP
  - Step/Chunk/Item Listeners
  - Retry Template
  - Transaction
  - Logging
- Spring Batch ist KEIN Scheduler



# **Spring Batch**



Quelle: spring.io



## "bulkCrawlerJob"

- Reader
  - CSV File
  - FlatFile Reader
- Processor
  - Crawler Implementierung
- Writer
  - Status loggen
  - später auch in die Datenbank

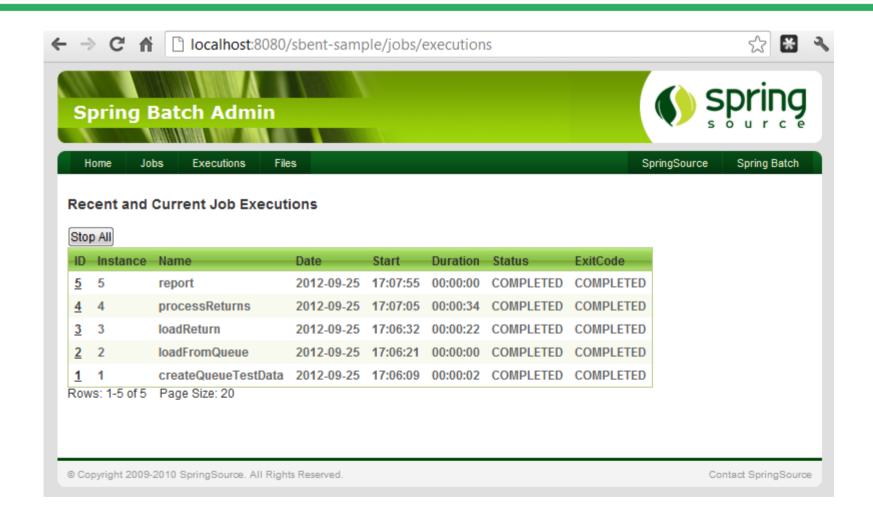


# HACKING...





# **Spring Batch Admin UI**





## Implementierung – Teil 3

- Datenmodell
  - CrawlerStatus
  - Produkt
- Statushandling
  - Modellierung Tabelle und Statusnetz
  - Status-Datenbank anbinden
  - Scheduling
- Partitionierung mit Spring Batch
- Konfiguration der Pooling (Thread-Pool, DBCP)

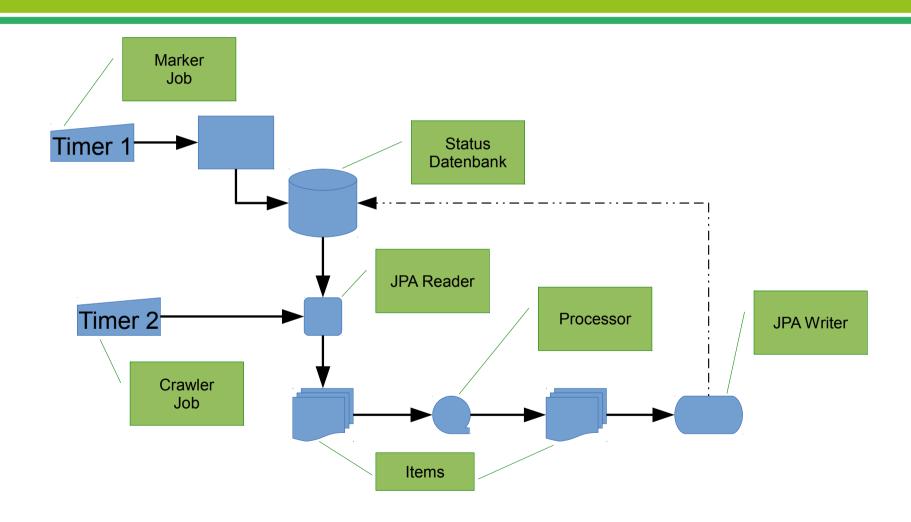


# HACKING...





# **Job Konfiguration - final**





#### "bulkCrawlerJob" - mit DB

- JPA Reader
  - ersetzt den CSV FlatFile reader
- JPA Writer
  - ersetzt den LoggingItemWriter
  - Status in Statusdatenbank via JPA
- zusätzlicher Job bulkCrawlerMarkerJob

#### **Status-Modell**

- Statusmodell (s. Tabelle)
- Statusnetz
  - FOUND
  - NOT\_FOUND
  - CHECK\_FAILED

| site_ident | isbn13                | priority | crawler_result | since_timestamp | latest_timestam<br>p | count |
|------------|-----------------------|----------|----------------|-----------------|----------------------|-------|
| HIVE_UK    | 978-1-408-<br>85567-6 | 90       | FOUND          | 09:15:00        | 19:35:05             | 4     |
| HIVE_UK    | 978-1-408-<br>12122-3 | 70       | FOUND          | 11:35:48        | 19:34:46             | 3     |
|            |                       |          |                |                 |                      |       |



# Scheduling-Logik

|           | Gestoppt            | Freigegeben                   |                    |
|-----------|---------------------|-------------------------------|--------------------|
| NOT_FOUND |                     | Prio 60<br>pub>7d<br>last>48h | Prio 5<br>last>60d |
| FOUND     | Prio 25<br>last>48h |                               | Prio 7<br>last>30d |
| null      | Prio 70             | Prio 85                       |                    |



# HACKING...

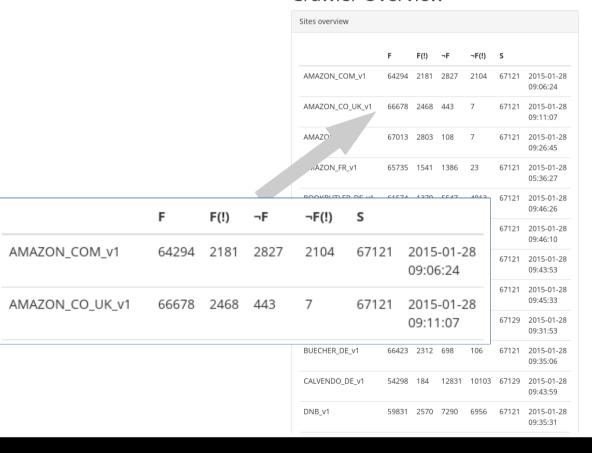




# Status/Visualisierung

tango Application - Dashboard - Daten - User - Suche

#### Crawler Overview



| Recently Crawled  |                   |       |                        |     |
|-------------------|-------------------|-------|------------------------|-----|
|                   |                   |       |                        | cnt |
| 978-3-660-89044-0 | WELTBILD_DE_v1    | FOUND | 2015-01-28<br>09:47:00 | 4   |
| 978-3-660-95377-0 | BOOKBUTLER_DE_v1  | FOUND | 2015-01-28<br>09:46:26 | 4   |
| 978-3-660-07918-0 | BUCH24_DE_v1      | FOUND | 2015-01-28<br>09:46:10 | 4   |
| 978-3-660-81644-0 | WELTBILD_DE_v1    | FOUND | 2015-01-28<br>09:45:58 | 4   |
| 978-3-660-07918-0 | BUCHKATALOG_DE_v1 | FOUND | 2015-01-28<br>09:45:33 | 4   |
| 978-3-660-30120-5 | BUCHKATALOG_DE_v1 | FOUND | 2015-01-28<br>09:44:26 | 4   |
| 978-3-660-41086-0 | EBAY_DE_v1        | FOUND | 2015-01-28<br>09:44:26 | 5   |
| 978-3-660-89044-0 | THALIA_DE_v1      | FOUND | 2015-01-28<br>09:44:13 | 4   |
| 978-3-664-06503-5 | BUCHKATALOG_DE_v1 | FOUND | 2015-01-28<br>09:44:13 | 6   |
| 978-3-660-71017-5 | CALVENDO_DE_v1    | FOUND | 2015-01-28<br>09:43:59 | 3   |
| 978-3-660-95377-0 | BUCHHANDEL_DE_v1  | FOUND | 2015-01-28<br>09:43:53 | 4   |
| 978-3-660-76207-5 | BUCH24_DE_v1      | FOUND | 2015-01-28<br>09:42:20 | 4   |



# **Status**

| Verfügbarkeitsmonitor        |          |      |                     |
|------------------------------|----------|------|---------------------|
| Seite                        | Status   | Link | Zuletzt überprüft   |
| Amazon COM                   | ~        |      | 2014-11-22 13:51:48 |
| Amazon UK                    | ~        |      | 2014-11-22 13:51:59 |
| Amazon DE                    | ~        |      | 2014-11-22 13:52:02 |
| Amazon FR                    | <b>~</b> |      | 2014-12-19 01:37:36 |
| pookbutler.de                | ×        |      | 2015-01-26 03:21:21 |
| puch24.de                    | <b>~</b> |      | 2014-11-19 08:56:09 |
| puchhandel.de                | <b>~</b> |      | 2014-11-22 13:22:36 |
| ouchkatalog.de               | <b>~</b> |      | 2014-11-22 13:52:08 |
| ouch.de                      | <b>~</b> |      | 2014-11-22 13:22:15 |
| ouecher.de                   | ~        |      | 2014-11-22 13:51:08 |
| CALVENDO.de                  | <b>~</b> |      | 2014-11-22 13:22:32 |
| Deutsche National Bibliothek | <b>~</b> |      | 2014-11-22 13:52:15 |
| ebay.de                      | <b>~</b> |      | 2014-11-22 13:51:23 |
| book.de                      | <b>~</b> |      | 2014-11-22 13:51:13 |
| nive.co.uk                   | ×        |      | 2015-01-26 03:21:22 |
| calenderhaus.de              | <b>~</b> |      | 2014-11-22 13:22:26 |
| halia.de                     | <b>~</b> |      | 2014-11-22 13:51:27 |
| veltbild.de                  | ×        |      | 2015-01-26 03:21:25 |

#### Links

- http://www.michaelnielsen.org/ddi/how-to-crawl-a-quarter-billion-webpages-in-40-hours/
- http://www.baeldung.com/httpclient4
- http://www.servage.net/blog/2013/04/08/rest-principles-explained
- http://en.wikipedia.org/wiki/Web\_crawler
- Oracle Java API Docs: ThreadPoolExecutor



#### Das war's...

Zumindest von meiner Seite...

Danke für die Aufmerksamkeit!